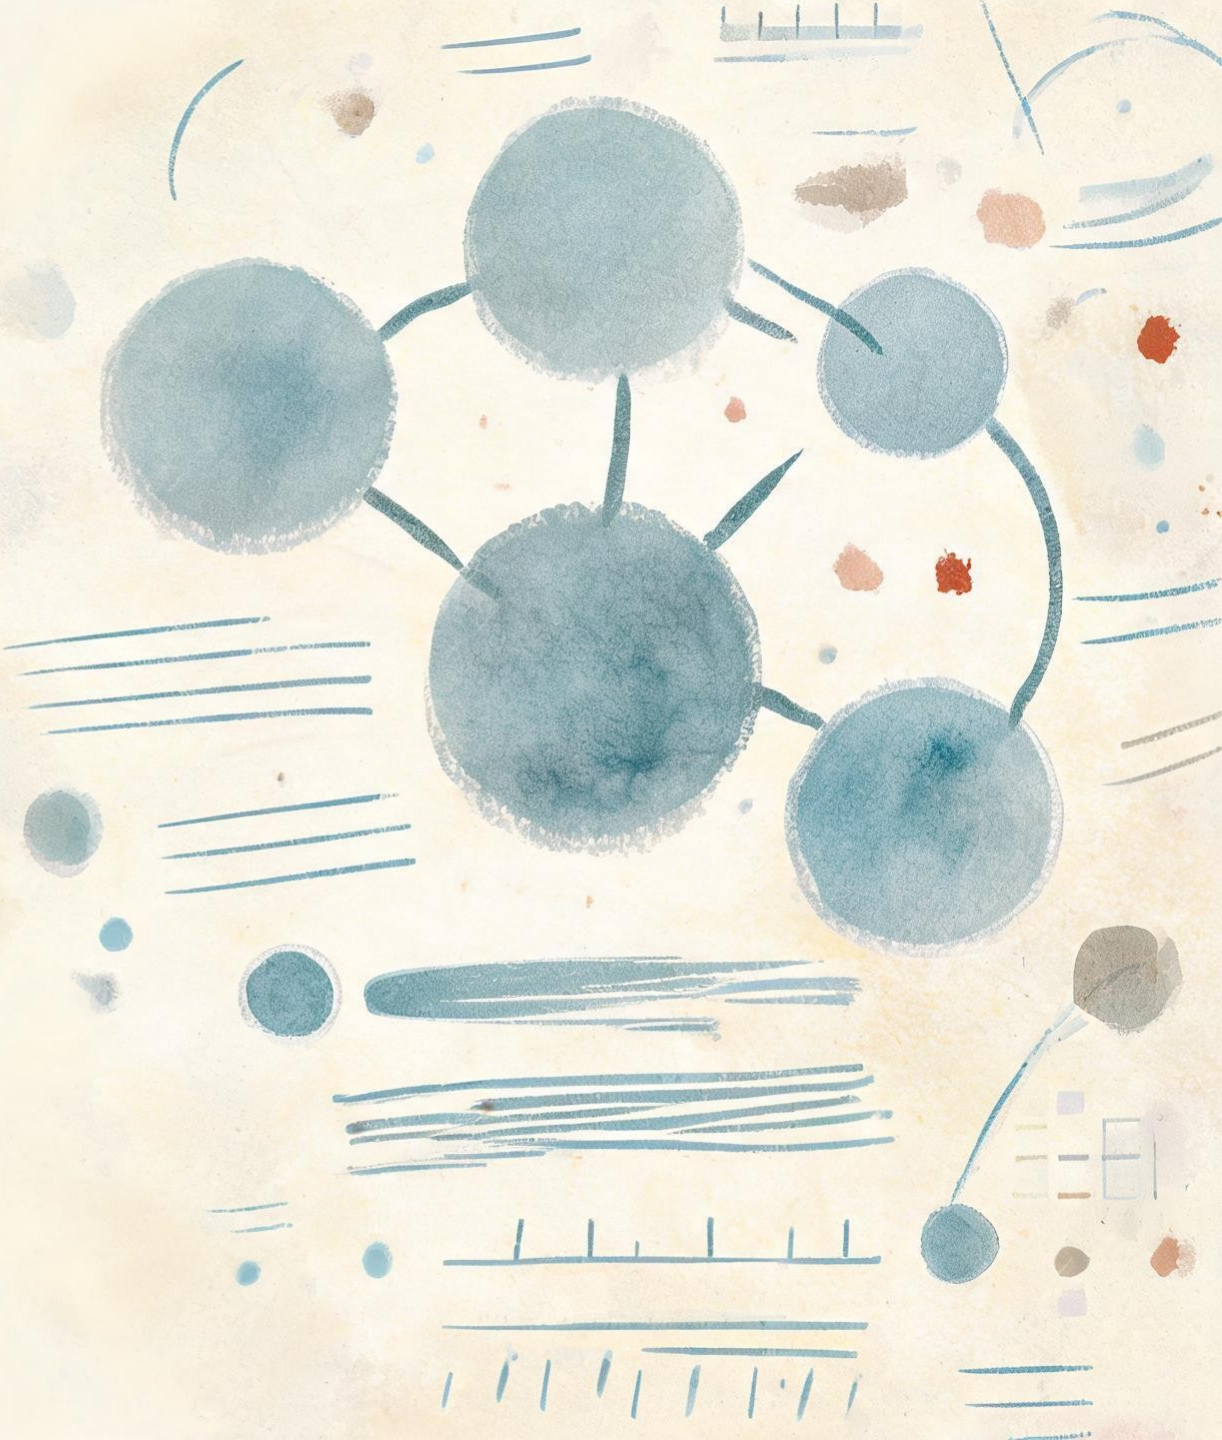
基于自然访谈与证据追溯的审辩式思维测评

让审辩式思维的过程证据可观察、可追溯、可复核

第二届 " 厚粲杯 " 全国大学生心理与认知智能测评挑战赛 · 测验赛道 · 企业命题十三

汇报日期： 2026 年 9 月



内容导航

01

研究缘起

从测评局限到研究问题

02

工具设计

六维框架与证据链评分

03

实证检验

开发集与锁定测试结果

04

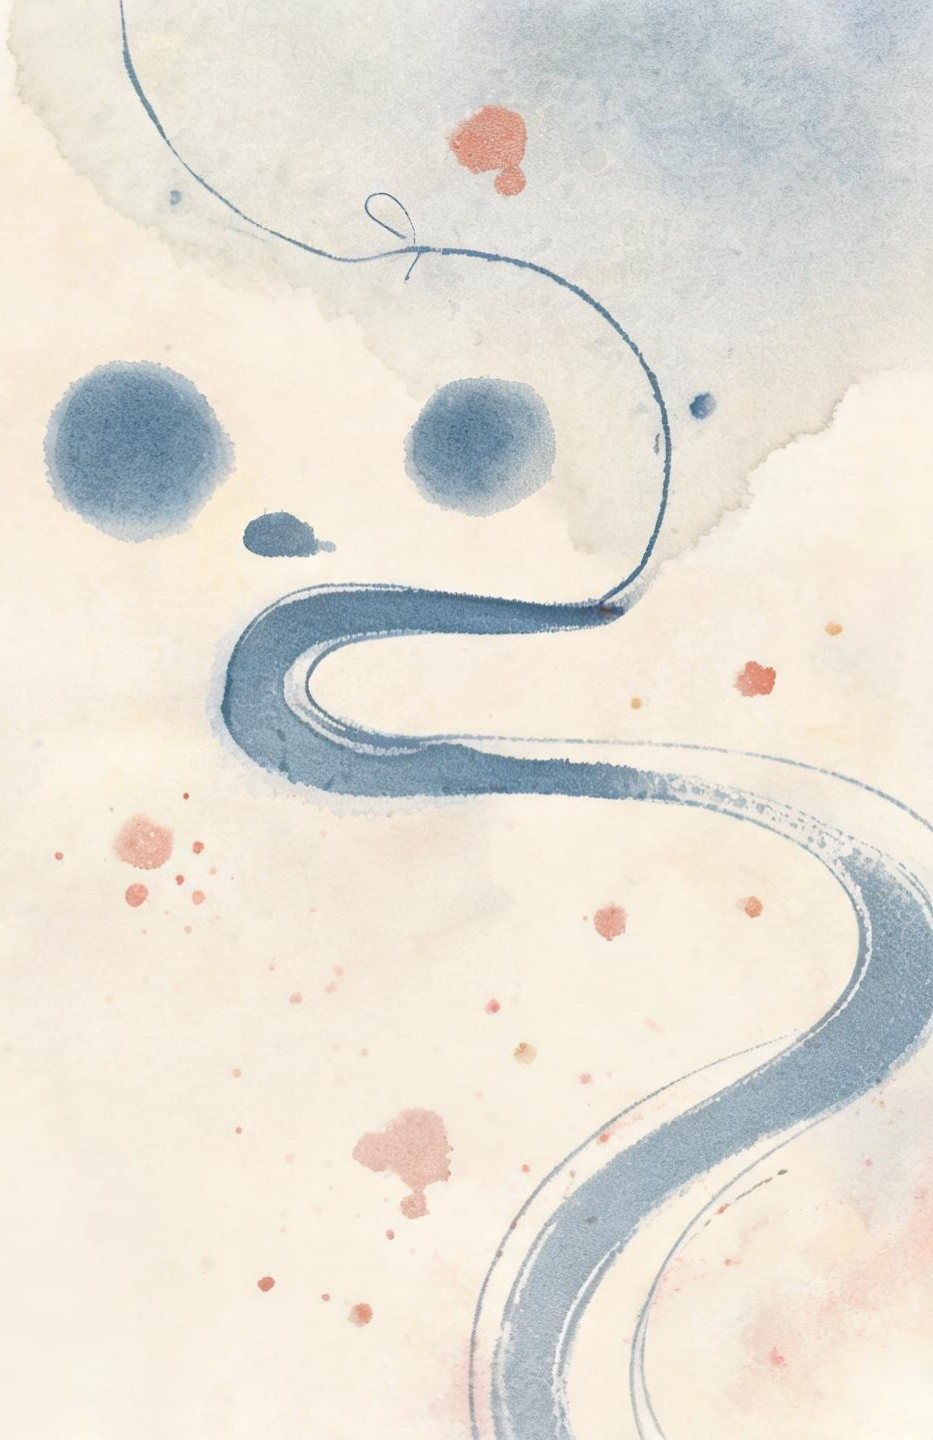
结论展望

适用边界与创新价值

01

研究缘起

让判断过程留在可检查的逐字稿中
从“谁答对了”走向“谁如何形成判断”



审辩式思维为何难以测评

静态测评只能记录结果，无法回溯判断过程

真实决策情境与构念本质

决策的复杂条件

学习、项目与职场决策常在**信息有限、证据更新、意见不一**的条件下，面临问题界定、信息核实、方案权衡与判断修正

构念的科学界定

不等于知识量、表达或一般认知能力： Facione （1990）界定为**有目的、可自我校正的判断**；Halpern （1998）强调认知策略的**选择、监控与迁移**

静态测评的根本局限

结论来源难以区分

若测量只记录最终选择，便难以区分结论来自**证据权衡**还是猜测、直觉或事后合理化

过程难以完整记录

标准化工具以固定题目与统一计分便于群体比较，但**含糊回答**无法继续核实、**简短结论**可能掩盖猜测，修正过程难以被一次作答完整记录

对话式测评的机遇与约束

多轮对话让判断形成与修正的中间环节，留在**可检查的逐字稿**中

证据获取方式的扩展

承接追问

多轮对话使访谈者能承接已有信息，继续追问 **理由、来源、反例、行动与结果**

虚拟代理研究

虚拟代理研究（Jackson & Zapata-Rivera, 2017; Zapata-Rivera et al., 2023）表明会话中可提出澄清与提示并**更新能力证据**

大语言模型的机遇与约束

降低分支成本

大语言模型降低了维护大量固定分支的成本，使围绕同一事件连续追问成为可能（Wuttke et al., 2025）

非测量保证

但这首先扩展 **证据获取方式**，并不预保测量更准确

追问尺度控制是核心难题

控制追问尺度

真正困难不在能否生成追问，而在 **如何控制追问尺度**：追问不足则关键证据缺失，追问过多或带答案暗示则可能把系统帮助误当作本人表现

本研究的限制

本研究将追问限制在明确的范围、帮助强度与停止条件内，每轮只提一个问题，并保留完整轮次以便事后检查证据如何产生

自动评分与人工作参照的双重检验

*自动评分依赖任务条件，人工参照标准亦需检验——**先验专家一致性，再比对自动评分***

自动评分的两重依赖

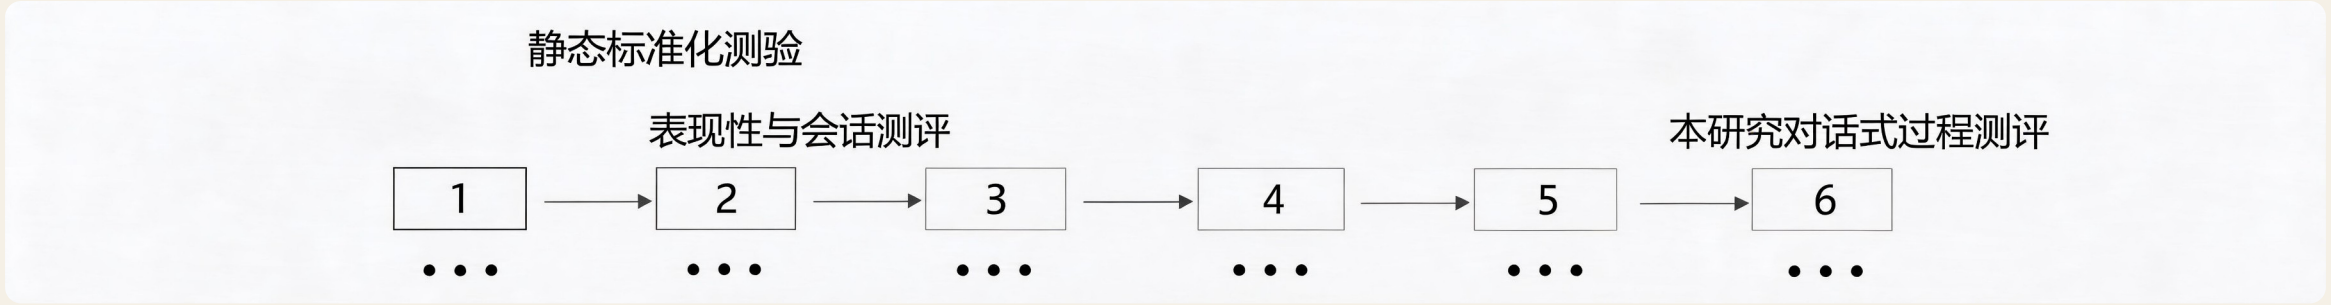
- 评分表现高度依赖**任务要求、模型版本、评价维度与输入顺序**；一次研究中的较高一致性，不足以证明模型成为稳定评分者（ Chiang & Lee, 2023; Wang et al., 2024 ）
- 语言流畅的解释未必忠实对应决定分数的材料，故要求评分能回到**具体轮次与参与者原话**，在等级判断前先处理证据归属、资格与可评分状态，证据不足保留 " 未测 "

人工参照的稳定性检验

- 自动评分的检验还取决于人工参照标准是否稳定：若评分者对**构念边界、行为锚点或可评分条件**理解不一，差异将与模型误差混淆（ Shrout & Fleiss, 1979; Hallgren, 2012 ）

因此本研究**先考察两位专家**使用同一评分手册的一致性，再比较自动评分与专家参照，避免把人工判断的全部差异简单归因于模型

从结果测评到过程证据的范式推进



范式谱系中的定位

静态标准化测验

固定题目与统一计分便于群体比较，但**难以回溯判断过程**

表现性与会话测评

扩展了证据获取方式，**评分可追溯性仍待解决**

本研究

多轮自然访谈 + 证据链评分，判断过程 **可观察、可定位、可复核**

三项学术创新

过程证据可观察

评分依据可回到**逐字稿**中参与者原话

证据资格先行

区分“表现较低”与“证据不足”（IE），**不把未展示误判为低能力**

追问尺度控制

追问限定在明确范围、**帮助强度与停止条件**内，每轮只提一个问题

研究目标与六维框架



目标一：构建可观察、可定位、可复核的行为证据体系

六维框架 问题界定 | 证据评估 | 推理论证 | 多元视角 | 整合决策 | 动态调整

处理流程 原话定位 → 来源归属 → 资格判断 → 状态判定 → 等级评分 → 结果留痕

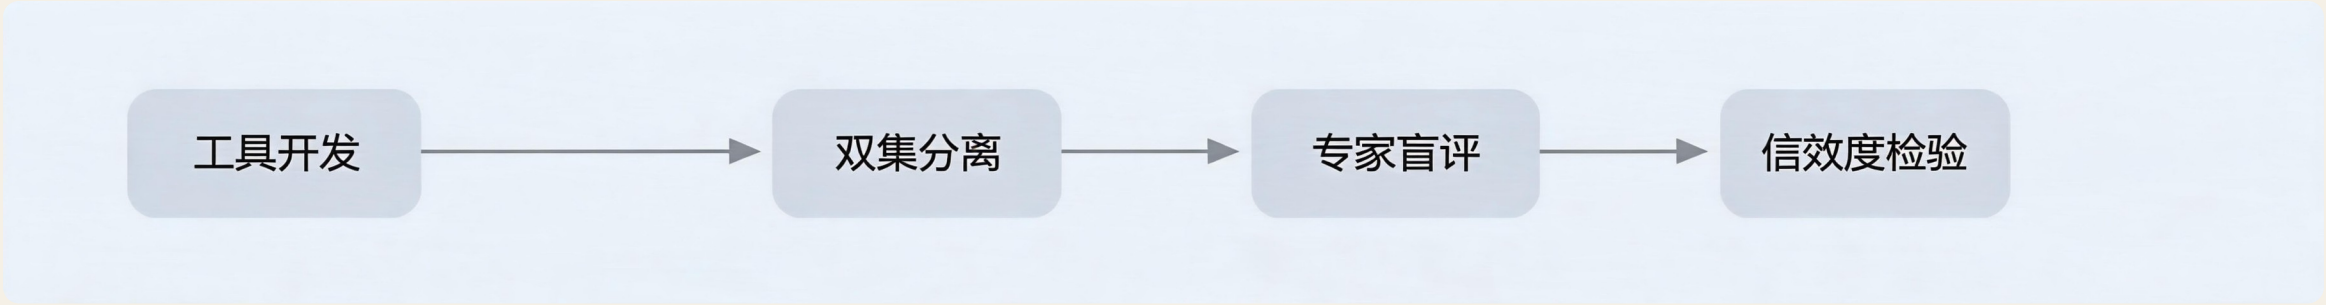
各维度设 **1—5 分** 行为锚点，**IE** 表示证据不足暂不判断，不以低分替代

目标二：基于真实决策经历的自然访谈测评工具

真实决策经历 以参与者本人真实决策经历为访谈素材，借鉴罗杰斯人本主义原则维持**自然对话**

定位 教学训练、项目复盘和**低风险发展性反馈**，为信效度检验与场景扩展奠定基础

三大研究假设



01 H1 证据收集

- **有效性**：基于个人经历访谈的工具能有效收集六维行为证据
- **覆盖率**：纳入多轮追问后，六个维度有效证据覆盖率显著提高，证据不足比例降低

02 H2 可追溯性

- **对应关系**：先提取行为证据再评分，使评分结果与对话原文对应关系更清晰
- **便于复核**：人工复核者能追溯评分依据

03 H3 人机一致性

- **偏差控制**：使用开发集确定并冻结的校准方案，独立锁定测试集上系统评分与专家评分的 **MAE** 与方向性偏差控制在可接受范围
- **一致性**：等级一致性 **QWK** 达到正向中等以上水平

研究假设 三条假设将研究目标转化为可检验的实证问题，分别对应**证据收集有效性、可追溯性**与**人机一致性**

02

工具设计

先判断证据资格，再评分
标准化追问与可回溯证据链的统一



样本筛选与双集分离设计

样本集	样本量	用途
开发集	**50 例**	评分方案比较及校准参数确定
桥接案例	**4 例**（开发集子集）	与锁定测试集构成专家盲评包，不进入锁定测试指标
独立锁定测试集	**21 例**	校准参数冻结后一次性验证方案性能
专家盲评包	**25 例**（4+21）	专家独立评分，计算人机一致性

完成者获 **20 元** 补偿 • 全部样本去标识化处理

人本主义风格的自适应追问

罗杰斯人本主义原则

访谈借鉴罗杰斯人本主义原则（Rogers, 1957），以参与者为中心、共情理解、尊重接纳、非评判回应，由参与者自选近期真实且需权衡的事件展开。

追问递进逻辑

追问遵循 **理解当前回答 → 识别信息缺口 → 生成下一问题** 的递进逻辑，每轮只提**一个主要问题**，不展示维度、锚点或标准答案。

访谈追问执行对照

环节	执行内容	主要限制
开场选题	**邀请选择真实、具体、需判断的事件**	**不替参与者选择事件**
事件澄清	**围绕背景、核心问题、依据、行动、结果与调整澄清**	**每轮最多一个主要问题**
中性承接	**简短复述或试探性理解，允许纠正**	**不赞扬、不暗示评分方向**
主线保持	**沿同一事件深入，跑题时温和拉回**	**不用固定阶段或题库控制**
证据整理	**每轮后独立任务完成原话定位与六维快照更新**	**访谈官不接收评分结果**
使用边界	**限教学训练、项目复盘与低风险反馈**	**不用于跨人排名或高风险决策**

六维评分框架与考察内容

六维评分框架

六维依据企业命题要求划分，每个维度分别独立判断，**一段回答可同时反映多个维度，不要求每个问题只对应一个维度**

维度	主要考察内容
问题界定	识别核心问题，明确范围与关键限制
证据评估	判断信息来源、可靠性、相关性及局限
推理论证	说明已有依据如何支持最终结论
多元视角	考虑不同相关者立场或其他可能解释
整合决策	综合信息、观点与现实条件进行权衡
动态调整	根据新信息、反馈或结果修正原有判断

五级评分共通等级与 IE 边界

各维度在共通等级含义上结合构念特征制定具体评分标准，分值越高表示表现越**充分、系统、灵活**

五级评分共通等级含义

评分状态	共通等级含义
1 分	**主要停留于复述、表态、单点判断或无依据结论**
2 分	**出现零散有效要素但关键部分缺失**
3 分	**达到基本可识别表现，深度或完整性有限**
4 分	**表现系统清晰且大部分完整，仍有实质缺口**
5 分	**表现完整可验证，能处理复杂性并说明边界**
IE	**证据不足**，不属于分数等级，不得因未展示记为 1 分

关键区分　**IE** 表示当前材料不足以判断，**1 分** 表示已获充分证据但表现较弱，两者不得互换；外部信息须经参与者独立分析后才可作评分证据。

证据提取与可回溯评分流程

评分不直接按整段对话形成总体印象分，而是先定位与六维相关的参与者原话，再判断评分资格，最后依据行为锚点给分

处理环节	主要内容
原话定位	从完整对话找出可能反映六维能力的原话并记录轮次
来源归属	判断内容是否属于参与者本人的判断或行为
资格判断	检查证据是否与目标维度相关且信息充分
状态判定	证据充分进入评分，不足时标记为 **IE**
等级评分	依据 **1—5 分**行为锚点综合判断合格证据
结果留痕	保存原话、维度、资格判断及评分理由供复核

留痕与隔离：后台每条证据记录包含原话切片、归属置信度、服务端校验状态与评分用途，各模块职责分离，报告生成模块**不重新修改分数或补充证据**

开发集 B0 至 B3 评分方案

- **50 例** 开发样本用于比较不同评分组的作用， B0—B3 使用相同访谈文本、模型版本与运行参数，仅改变评分时提供的信息及处理步骤。
- 两位专家独立评价并通过**冲突裁定**形成专家参照评分。

四组评分方式对比

评分条件	主要处理方式	主要目的
B0	直接阅读完整对话并评分	直接评分基线
B1	在 B0 基础上加入完整六维评分手册	检验行为锚点作用
B2	先提取参与者原话证据再评分	检验证据先行机制
B3	在 B2 基础上增加证据归属与资格判断	排除不符合要求的材料

B4 **冻结平移校准**：仅用开发集估计 B0 相对专家的系统性偏差，确定固定平移值并预先冻结截断与取整规则，**不改变原始评分流程和证据判断过程。**

监督微调实验设计

以专家评分为目标，通过五折交叉验证与三组对照设计训练通义千问模型



模型与训练策略

基座模型

通义千问 Qwen3-1.7B，以专家参照评分为训练目标，采用 **LoRA 低秩适配**，冻结原参数只训练少量附加参数

数据划分

50 例开发样本产生 **300 个评分条目**（每例 6 维），五折交叉验证每次 **40 例训练、 10 例验证**，同一案例六维始终同组，防止访谈内容泄漏

加权策略

IE 加权微调将证据不足样本训练权重提高至普通样本的 **4 倍**

三组对照实验

01 **对照一**：未微调模型直接评分

02 **对照二**：后校准，按开发集平均差距统一加减固定值

03 **对照三**：维度中位数预测，所有验证案例预测同一维度中位数

五折完成后用全部 50 例训练模型，再对 T21 保留样本评分

结构化报告模块与解释边界

系统将六维分数、行为证据与**证据充分性状态**写入固定报告结构，便于跨参与者比较与人工复核。

报告模块	呈现内容
结果概览	完成情况及六维结果分布
维度结果	各维度的 1—5 分评分或 IE 状态
行为证据	支持判断的参与者原话及所在轮次
优势表现	证据充分且表现较好的能力及依据
改进建议	根据现有证据提出的练习方向
发展计划	将改进建议转化为可执行行动
结果边界	证据不足情况及报告适用范围

⚖️ 报告生成智能体**只整理和解释已确定的评分结果**，不再重新评分，也不补充对话中没有出现的行为证据； IE 维度统一标记并说明不足，**不解释为低能力**。

系统架构与多 Agent 分工

前后端分离 Web 架构：前端 **Vue 3** 负责访谈界面与报告呈现，后端 **Python FastAPI** 负责会话管理与流程控制， **MySQL** 保存逐字稿与评分数据， AI 能力经 **DeepSeek API** 调用。

系统层级	技术实现	主要作用
用户交互层	Vue 3	展示访谈页面、接收回答、呈现报告
业务服务层	FastAPI	管理会话状态并控制测评流程
模型服务层	DeepSeek API	生成访谈回复并完成智能处理
数据存储层	MySQL	保存对话、证据、评分及报告
工具连接层	MCP	提供统一的智能体工具调用接口

功能模块	主要职责	主要输出
访谈主持	承接回答并维持自然对话	面向参与者的回复
追问规划	判断是否需要继续展开	下一轮追问目标
证据识别	定位原话并判断证据是否合格	行为证据及 IE 状态
自动评分	依据六维行为锚点评分	六维分数及评分理由
报告生成	整理已确定的评分结果	六维结构化报告

MCP 协议统一工具调用

系统通过**模型上下文协议（MCP）**封装**证据归属、六维评分和报告生成**三个工具，复用现有后端服务。

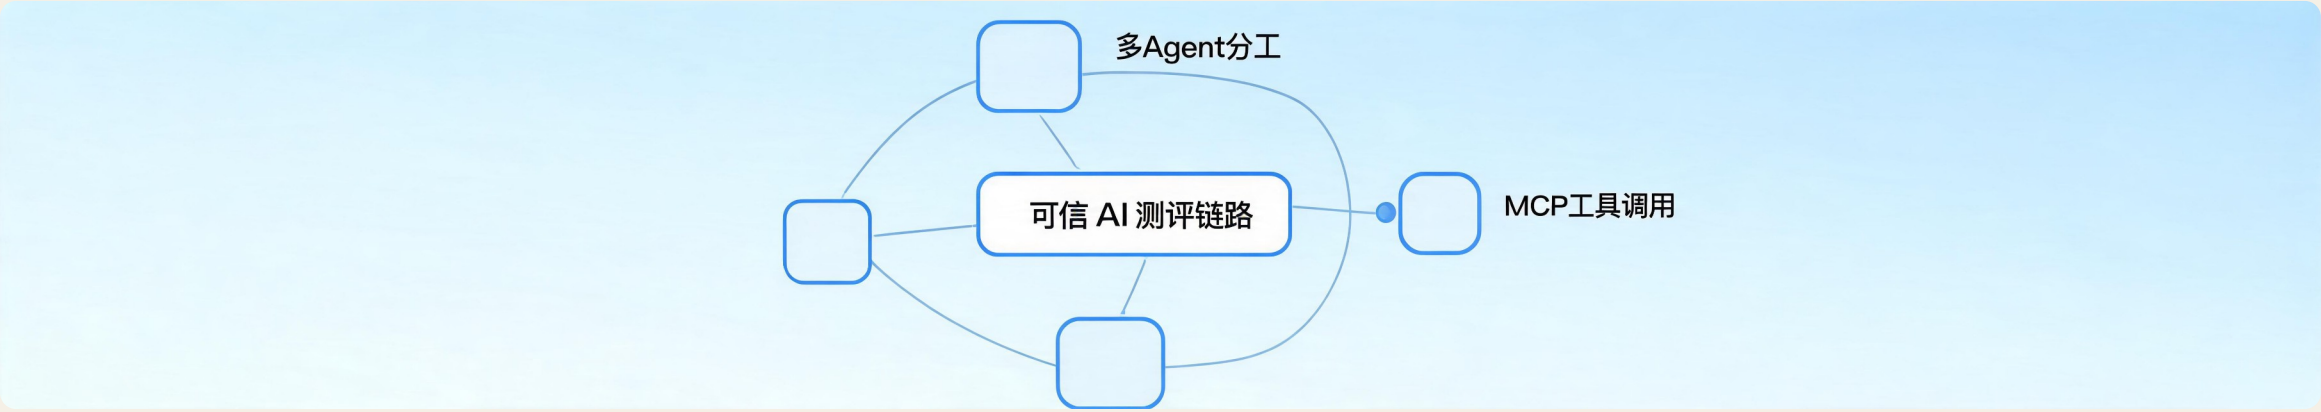
工具	主要输入	主要输出	关键约束
attribute_evidence	含轮次、角色与文本的逐字稿	证据标识、来源归属、资格状态、原文位置	后续调用使用服务端登记的证据
score_six_dimensions	同一逐字稿及合格证据标识集合	六维评分、状态、理由、置信度及证据引用	核验证据集合，区分评分、 IE 与执行错误
generate_report	已登记的六维评分及证据信息	六维结构化报告	核对评分与证据记录，拒绝不一致输入

⚠️ 证据不足（IE）与执行错误（ERROR）均**不赋予数值分数**，执行错误不得转换为证据不足后继续生成报告。

系统通过 MCP 封装三个工具，复用现有后端服务，与 Web 主流程共享证据处理、评分和报告生成逻辑。

AI 工程创新：可信测评链路

从架构、接口、训练到纪律约束，构建可信、可复核的 AI 测评工程链路



多智能体职责分离

访谈主持、追问规划、证据识别、自动评分、报告生成五个模块各司其职，通过结构化数据传递，互不越界。

MCP 协议与证据服务端登记

三个 MCP 工具封装证据归属、六维评分与报告生成；证据标识由服务端登记，评分只能引用已登记证据，保证**评分与证据一致**。

IE 加权微调

以 **Qwen3-1.7B** 为基座、LoRA 低秩适配，证据不足样本训练权重提高至普通样本的 **4 倍**。

执行纪律约束

执行错误（ERROR）不得转为证据不足（IE）后继续生成报告；报告生成**不重新评分、不补造证据**。

系统总体架构、智能体结构与应用界面设计







03

实证检验

用独立样本检验冻结方案
多轮增益、评分稳定性与微调探索



多元信效度证据与分析框架

全部指标在开发集优化、参数冻结后于独立锁定测试集一次性验证，避免数据驱动带来的性能高估

双样本验证设计：**开发集优化** → **参数冻结** → **锁定测试一次性验证**

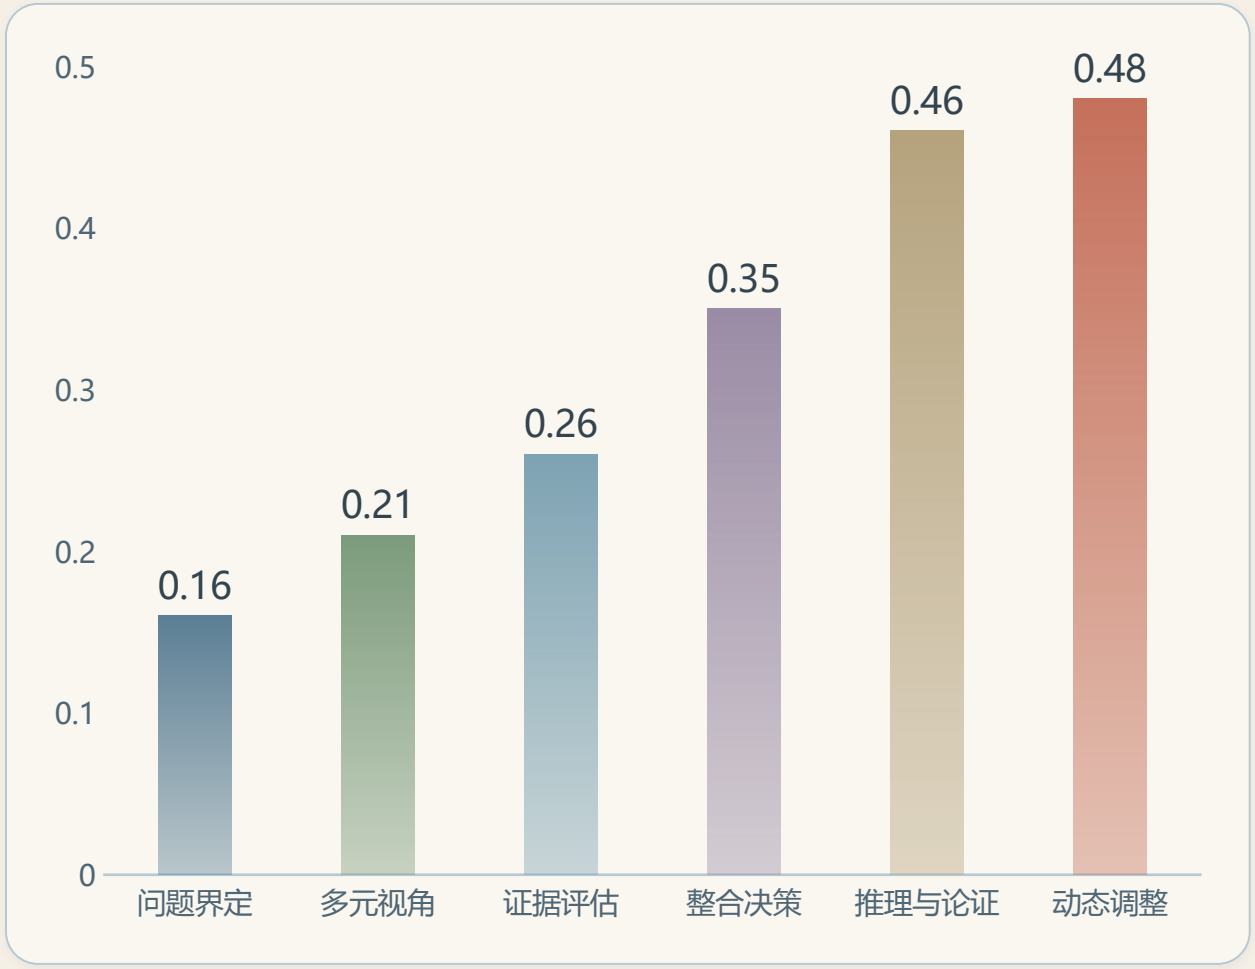
证据类型	主要指标	回答的问题
一致性	**ICC(2,1)** 、 **ICC(2,k)** 、 **QWK**	专家之间、模型与专家是否一致
效度	**Cronbach α** 、**分半信度**、 **MTMM**	六维结构是否可靠、能否区分
误差	**MAE** 、**方向性偏差**	评分偏离多少、是否系统性偏低
分类	**Precision** 、 **Recall** 、 **F1**	证据不足（IE）识别是否可靠
可用性	**完成率**、**作答时长**、**异常率**	工具能否在真实场景中使用

各指标结果均同时报告**开发集**与**锁定测试**表现，并逐项说明**解释边界**

专家评分一致性存在维度差异

50 例开发集共 300 个评分单元，其中 275 个获两位专家数值评分， QWK 介于 0.16 与 0.48 之间，专家一致性存在明显维度差异

六维度专家评分 QWK 对比



评分一致性解读

评分总量 **300** 个评分单元（50 例开发集）

有效评分 **275** 个获两位专家数值评分

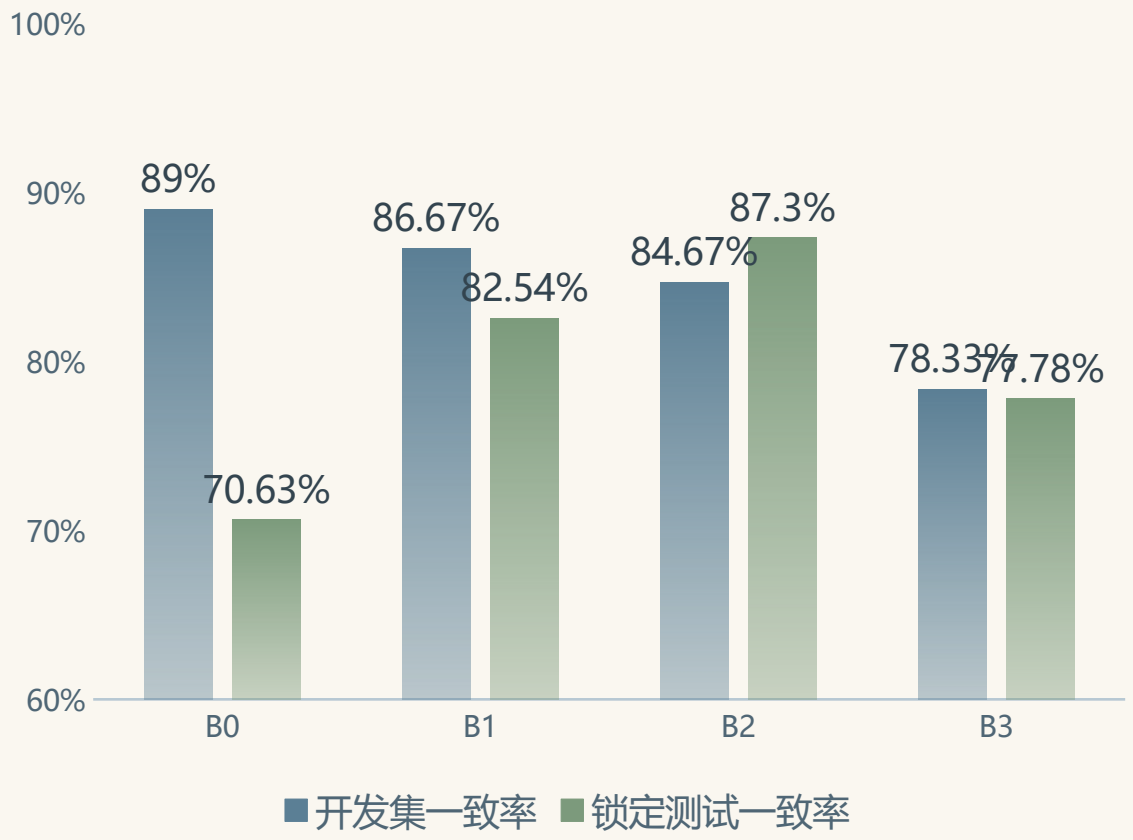
QWK 区间 介于 **0.16–0.48**，存在明显维度差异

总体 ICC ICC(2,1) **0.32**、ICC(2,k) **0.48**，可作当前开发参照

改进方向 加强**评分者训练**、**边界案例讨论**与**评分锚点细化**

模型重复运行稳定性排序不固定

在输入材料、模型版本、提示词与生成参数不变条件下， B0 至 B3 各运行三次，考察模型重复输出稳定性。



各方案重复输出一致率

89.00% B0 开发集最高，锁定测试 70.63%

86.67% B1 降至 82.54%

87.30% B2 升至锁定测试最高

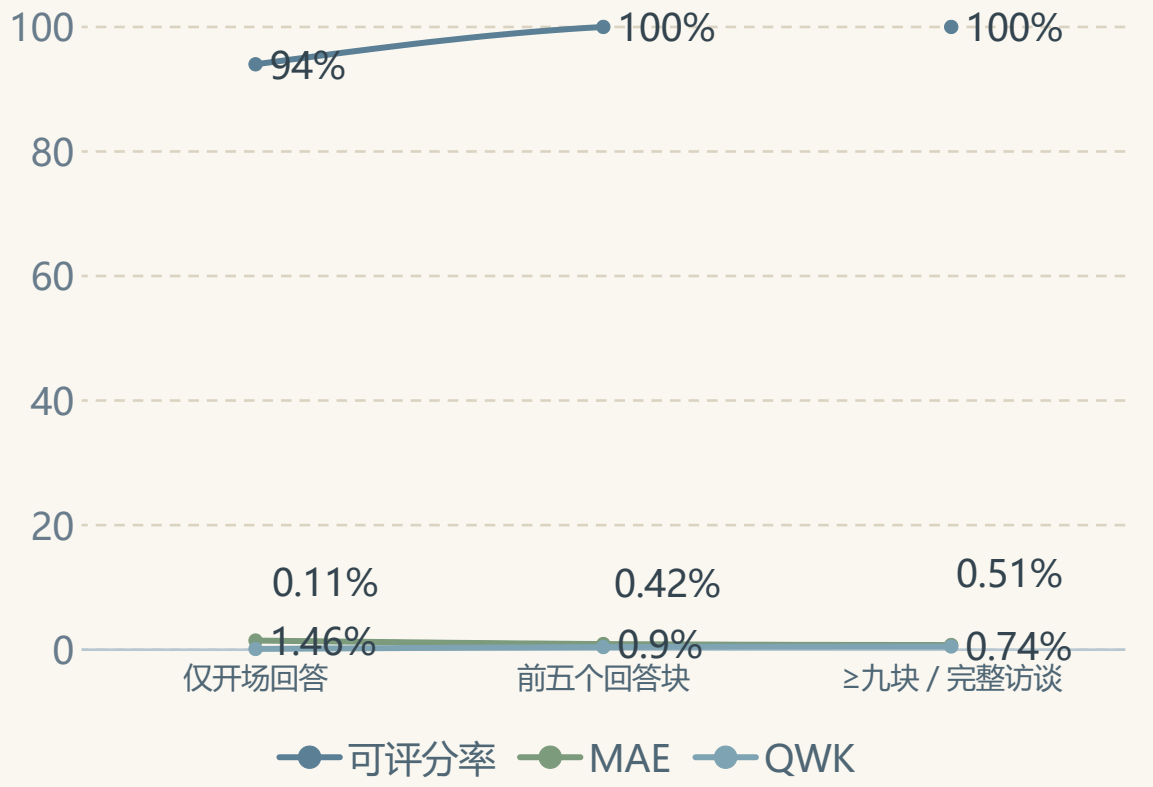
78.33% B3 与 77.78% 基本持平

⚖ 稳定性排序不固定：该检验针对模型重复输出，**不属于被试重测信度。**

多轮回答持续增加可评分证据

仅使用开场回答时，可评分率 94.00% 、 MAE 1.46 、 QWK 0.11 ； 纳入前五个回答块后，可评分率提高至 100.00% ， MAE 下降至 0.90 ， QWK 提高至 0.42

三阶段可评分率与 MAE 、 QWK 趋势



94.00%→100%

可评分率

1.46→0.90→0.74

MAE

0.11→0.42→0.51

QWK

0.00%→31.82%→43.18%

高分召回率

早期追问提供**主要新增信息**，后续增益逐步收窄

六维内部一致性较高

六个维度作为六个测量项目计算内部一致性，某一维度得分较高的参与者通常在其他维度也有较高得分，表明六维得分具有较强共同变化趋势，但不能单独作为六维结构成立的充分证据。

六维得分具有较强**共同变化趋势**，但不能单独作为六维结构成立的充分证据。

缺失值处理方式	案例数	Cronbach α	分半信度
成对删除	50	0.91	0.94
列表删除	41	0.92	0.96

六维区分效度尚未显现

检验指标	结果	主要解释
同特质跨方法相关均值	**0.45** [0.27, 0.59]	未高于不同特质跨方法相关
不同特质跨方法相关均值	**0.45** [0.27, 0.58]	跨方法区分不充分
不同特质同方法相关均值	**0.69** [0.60, 0.76]	同一评分方法产生较强共同影响
同特质跨方法优势值	**0.002** [−0.022, 0.030]	区间包含 0

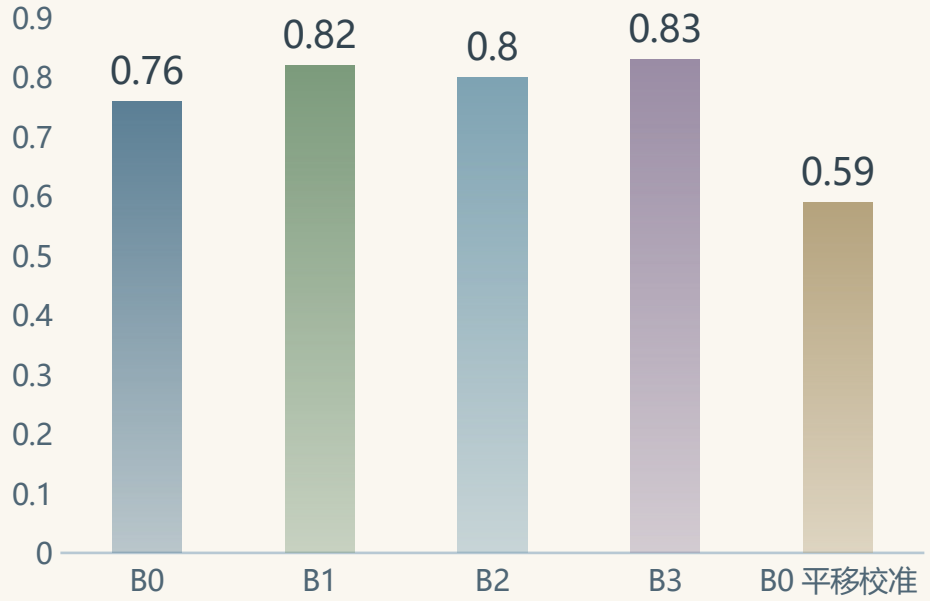
六维 Pearson 相关介于 **0.43 至 0.77** 之间，15 组关系均达显著，但 MTMM 结果显示区分证据不足

同一评分来源给出的不同维度分数反而更接近，提示结果可能受评分者 **整体印象** 影响，现有数据只能提供初步构念关系证据，尚不能证明六维构念效度良好

B0 在开发集获得最优数值指标

开发集上 **B0** 在四套原始评分方案中 **MAE 最低 0.76**、**QWK 最高 0.50**

0.59 MAE 平移校准
0.63 QWK 留一法



评分方案	数值配对数	数值覆盖率	MAE	QWK	方向性偏差
B0	289	100.00%	0.76	0.50	−0.64
B1	289	100.00%	0.82	0.42	−0.69
B2	289	100.00%	0.80	0.45	−0.68
B3	282	97.58%	0.83	0.48	−0.74
B0 平移校准（留一）	289	100.00%	0.59	0.63	−0.14

- 方向性偏差按 AI 评分减专家参照计算，负值表示 **AI 整体偏低**，四方案均存在**系统性低估**

冻结校准缓解锁定测试低估

锁定测试中 B0 至 B3 原始评分整体低于专家参照，使用冻结平移校准后 B0 的 MAE 、 QWK 与方向性偏差均明显改善

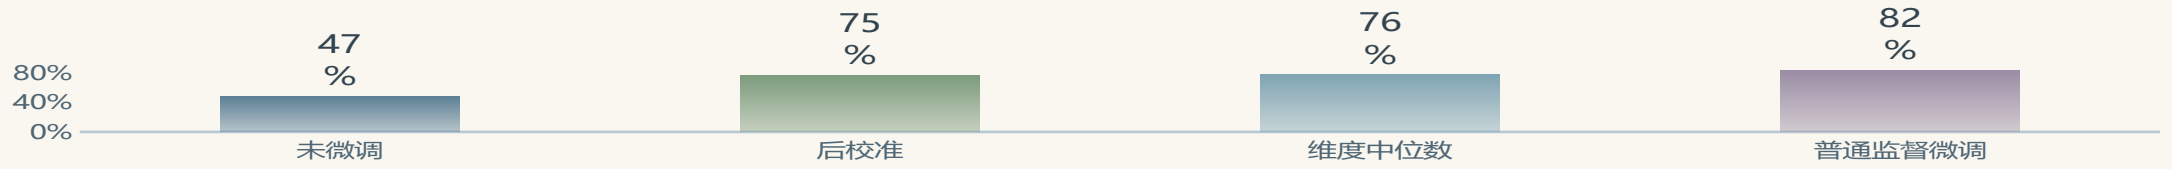
评分方案	MAE	QWK	方向性偏差	误差不超过 1 分比例
B0	**1.23**	0.22	−1.14	**46.94%**
B1	1.17	0.30	−1.15	50.00%
B2	1.18	0.30	−1.16	48.98%
B3	1.35	0.28	−1.33	40.82%
B0 冻结平移校准	**0.86**	**0.35**	**−0.64**	**81.63%**

> 冻结校准使 B0 的 MAE 由 **1.23** **降至** **0.86** 、误差不超过 1 分比例由 **46.94%** **提高至** **81.63%** ，但仍存在平均 **0.64 分** 的低估，且证据不足识别能力未获改善

监督微调改善开发集评分表现

82.00% | 监督微调后容差成功率 **82.00%**， MAE 降至 **0.65**， 显著优于**未微调基线**

容差成功率对比



方法	参与条目数	MAE↓	QWK↑	容差成功率↑
未微调模型	268	1.23	0.07	47.00%
未微调模型 + 后校准	268	0.73	0.16	75.00%
维度中位数预测	289	0.71	0.06	76.00%
普通监督微调	**289**	**0.65**	**0.42**	**82.00%**

利用已有专家评分训练能改善该模型在开发样本上的表现

微调优势未延续到保留样本

T21 历史保留验证中，普通微调模型未能保持开发集优势

01 T21 保留样本微调验证

指标改善但误差扩大

- QWK 由 **0.10** 提高至 **0.22**
- MAE 由 **0.77** 升至 **1.05**
- 容差成功率由 **71.43%** 降至 **51.26%**

微调在开发样本上的改善未能在另一批案例中保持，**反而误差增大**

开发样本上的改善未能延续至 T21 保留样本

方法	MAE↓	QWK↑	容差成功率↑
未微调模型	0.77	0.10	71.43%（85/119）
未微调模型 + 后校准	0.78	0.08	58.82%（70/119）
维度中位数预测	0.99	0.08	57.98%（69/119）
普通监督微调	1.05	0.22	51.26%（61/119）
IE 加权微调（×4）	0.98	0.25	56.30%（67/119）

证据不足识别能力仍然不足

B3 是唯一设置证据来源归属与 IE 判断的方案，但**锁定样本 Recall 仅 0.05**， IE 识别尚不可靠。

IE 识别混淆矩阵

数据集	专家参照 IE 数	预测 IE 数	TP	FP	FN	Precision	Recall	F1
开发集	11	9	2	7	9	0.22	0.18	0.20
锁定样本	21	1	1	0	20	1.00	0.05	0.09

漏判分析与警示

- 开发集 11 个参照 IE 中 **8 个集中在动态调整维度**，提示部分访谈未提供充分判断修正机会。
- 锁定样本 21 个 IE 中**仅识别出 1 个**，存在严重漏判。
- 尚未形成**稳定的证据不足识别能力**，必须保留人工判断。

会话作答时长分布

46 例不超过 30 分钟，占 93.88%（中位数 11.55 分钟）

剔除 1 例超过 60 分钟异常间隔案例

统计指标	结果
有效案例数	**49**
平均值	**13.24** 分钟
中位数	**11.55** 分钟
标准差	**8.96** 分钟
第 95 百分位数	**28.43** 分钟
最大值	**47.70** 分钟
不超过 30 分钟	**46 例**， **93.88%**
超过 30 分钟	**3 例**， 6.12%

该跨度统计首个至末次参与者回答的时间，不包含知情同意与报告查看时间，因此**不等同完整端到端测评耗时**

04

结论展望

结论边界清晰，价值定位审慎
低风险发展性反馈，而非高利害决策



主要研究发现综合说明

评价方面	主要结果	可支持结论	解释边界
多轮信息	可评分率 **94.00%→100.00%** ， QWK **0.11→0.51**	后续回答能补充过程证据	不能证明自适应追问具有因果优势
原始评分	B0 至 B3 无稳定性能排序	复杂流程不会自动提高准确性	证据链审计价值应单独评价
冻结校准	MAE 由 **1.23** 降至 **0.86**	固定校准缓解系统性低估	仍存负向偏差，不能改善 IE 识别
评分信度	专家 QWK 为 **0.16** 至 **0.48**	评分规则仍需细化	模型重复运行不属于重测信度
构念证据	内部一致性较高	六维得分有共同变化趋势	尚不能证明六维已清晰区分
IE 识别	开发集 F1 为 **0.20** ，锁定 F1 为 **0.09**	系统已能输出 IE 状态	识别能力不足，须保留人工判断
测评时长	46 例不超过 30 分钟，占 **93.88%**	多数会话符合时间目标	统计值不等同端到端耗时
监督微调	开发集 **82.00%** ， T21 降至 **51.26%**	微调改善开发样本表现	保留样本未保持优势

H1 获初步支持：多轮问答构成测量增益

H1 获得最明确的积极结果：**多轮追问为补充理由、说明依据和修正观点提供机会**

关键指标变化

3 类信息量

仅开场回答

可评分率 **94.00%** · MAE **1.46** · QWK **0.11**

前五个回答块

可评分率 **100.00%** · MAE **0.90** · QWK **0.42**

后续回答

可评分率 **100.00%** · MAE **0.74** · QWK **0.51**

增益分布与停止规则

停止规则

- **前五个回答块贡献主要改善**
- **达九个回答块后增益逐步收窄**
- **停止规则依据：判断证据是否充分而非机械追求更多轮次**

多轮追问的机制解释

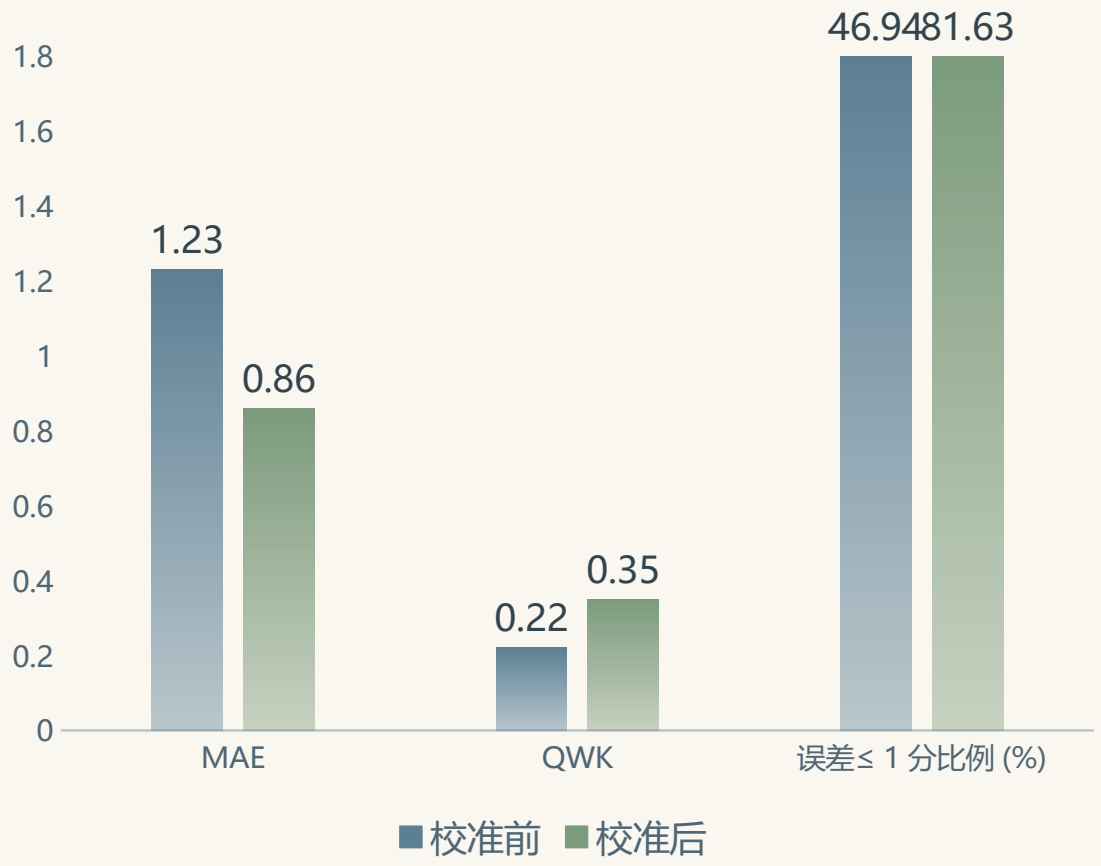
参与者难以在一次回答中完整呈现**问题界定、证据评估、推理论证与判断调整**

多轮追问为补充理由、说明依据和修正观点提供机会

H2 与 H3 获初步支持

B0 至 B3 比较表明，增加评分环节并不会自动提高数值表现，但不能仅凭 MAE 与 QWK 否定证据先行评分的价值。

H3 冻结校准：关键指标全面改善



误差不超过 1 分比例按百分数显示，其余为原值

✅ H2 可追溯性：证据链价值获方向性支持

- **B2** 和 **B3** 能为评分提供**原话位置、证据来源**与**排除理由**
- 为人工复核建立**可追溯证据链**，与 H2 预期方向一致

边界条件 校准后仍存 **0.64 分** 低估、未改善 IE 识别，专家 QWK 介于 **0.16 至 0.48**

信度效度与微调推广的边界

综合讨论内部一致性、区分效度、 IE 识别与微调未延续等问题，明确这些结果对构念证据与模型泛化的含义

六维得分关联较强，但**尚不能证明**六个维度能被不同评分来源稳定区分

01 部分一 内部一致性与区分效度

- 六维得分能共同反映审辩式思维的**一般水平**。
- 较高内部一致性可能来自维度内容**重叠**、共同评分方法或评分者**整体印象**。

02 部分二 IE 识别表现

- B3 开发集 F1 为 **0.20** 、锁定测试仅 **0.09** ，存在明显漏判。
- 开发集 11 个专家参照 IE 中 **8 个**集中在动态调整维度，提示部分访谈未提供充分的判断修正机会。
- 需改善**动态信息投放**与**追问设计**。

03 部分三 微调推广边界

- 利用专家评分训练 Qwen3-1.7B 可改善开发样本表现，但保留样本上 MAE 反而增大、容差成功率下降，**开发样本上的改善尚不能直接推广到其他样本**。
- 两批样本专家评分分布差异未必来自参与者表现或评分尺度变化，**现有证据不足以判断**。

工具的分层应用与人工复核

低风险应用场景

- **培训反馈**：聚焦 " 下一次可以怎样做得更完整 " ，改进建议对应具体证据，避免通用建议

- **自我反思**：按 " 本次表现—原话证据—可能不足—改进方法 " 组织；证据充分维度呈现分数与原话，证据不足维度明确标记 **IE** 并建议追加追问，不将 IE 直接转换为低分

- **人才发展与研究试测**：作为发展性工具使用

人工复核与追问节奏

- **自动标记转入人工复核的情形**：证据不足、专家间有争议、极端分数、重复运行差异过大及 **高风险用途**

- **高风险决策边界**：招聘、晋升和淘汰等重要决定仍需结合人工访谈、实际表现及其他测评材料综合作出

- **追问原则**：围绕实际证据缺口展开，特别是动态调整维度需先提供新信息再观察是否修正判断；当无法补充或始终无行为证据时停止追问并将缺失维度标记为 IE

研究局限与结论边界

*研究结论应止步于当前样本与任务边界，**不宜向外过度推断***

样本与人工参照

50 例反复修订
难以排除过拟合

21 例锁定样本
样本量小，**置信区间较宽**

25 例盲评包
两批非同样本，仅 **4 例桥接案例**

锁定测试参照
两位专家合成，**未设第三位裁定**

微调泛化

50 例训练数据
优势**未在 T21 延续**

证据不足条目
两种微调**均未正确识别**
尚不足支持跨样本稳定评分

效度与外推

结构效度未验
数据不足检验因素稳定性 / 跨群体等值性 / 常模 / 预测效度

信息量条件
同逐字稿截断，非追问随机分配
不能证明追问有因果优势

校准常数

固定平移校准
锁定测试同向改善，**仍留较大残余偏差**

不可直接沿用
该常数**不可跨人群 / 任务 / 标准**沿用

综上：研究结论**止步于当前样本与任务边界**，不向外过度推断

未来研究方向

01 研究建议 扩大独立样本

- **预先注册**分析方案与冻结版本
- 以同一批案例比较**评分手册修订前后**的专家判断
- 引入**外部专家盲评**或标准化测验

02 研究建议 前瞻性实验

- 比较**追问策略**
- 在**控制帮助强度**的同时检验**信息增量**

03 研究建议 效度深化

- 持续考察**因素结构、跨群体等值性**
- 测评结果与学习或工作表现的**预测效度**关系

04 研究建议 贡献定位

- 形成并初步检验以**自然访谈、过程证据和可复核评分**为核心的测评路径
- 而非证明**自动评分能够替代专家**

三层创新：范式 · 机制 · 工程

学术创新：过程证据范式

真实决策经历为起点

以真实决策经历为起点**逐轮追问**

逐字稿证据

判断形成与修正转化为**可定位、可回溯**的逐字稿证据

判断如何形成

从“谁答对了”推进到**“谁如何形成判断”**

评分机制创新：证据资格先行

证据资格区分

严格区分**“表现较低”**与**“尚未获得充分证据”（IE）**

来源不明不计低分

来源不明的材料**不直接计入低分**

评分逐级可回溯

评分可逐级回溯至**参与者原话**

工程与验证创新：可信 AI 测评链路

证据链逐级复用

多 Agent 职责分离与 **MCP 标准化接口**支持证据链逐级复用

独立锁定测试

方案冻结后**独立锁定测试**

结论限定证据范围

每项结论**限定在现有证据能支持的范围内**

让审辩式思维测评回到证据本身

测评的价值不在于给出一个分数，
而在于让每一个分数都能回到原话、回到证据、回到判断过程

以自然访谈获取过程证据，以证据链支撑可复核评分

